

多目标优化与机器学习前沿交叉及工程应用

——夏令营学术讲座深度学案与学术笔记

笔记整理人：数学系本科生

指导老师：李辉教授（西安交通大学数学与统计学院）

2026 年 7 月 14 日

目录

1	引言与多目标优化背景	3
1.1	多目标优化问题的工程应用实例	3
2	多目标优化的数学理论基础	4
2.1	标准数学模型	4
2.2	帕累托支配与最优性理论	4
2.3	多目标优化问题的关键挑战特征	5
3	传统方法与进化算法求解	5
3.1	传统单目标化求解方法	6
3.1.1	加权和法 (Weighted Sum Method)	6
3.1.2	ϵ -约束法 (ϵ -Constraint Method)	6
3.2	多目标进化算法 (MOEA) 机制	6
3.2.1	NSGA-II (Deb et al., 2000)	6
3.2.2	MOEA/D (Zhang & Li, 2007)	7
4	多目标优化与机器学习的前沿交叉研究	7
4.1	工作一：基于流形分布估计的进化算法 (RMM-EDA)	7
4.1.1	流形分布的数学机理	8
4.1.2	局部主成分分析 (Local PCA) 精准推导	8
4.2	工作二：克里金模型与昂贵优化算法 (MOEA/D-EGO)	8
4.2.1	高斯随机过程模型 (Kriging / Gaussian Process) 的形式化推导	9
4.2.2	极大化期望改进 (Expected Improvement, EI) 机制	9
4.3	工作三：基于多目标优化的稀疏重构与稀疏学习 (SPLS)	9
4.3.1	稀疏 L_0 双目标问题转化	10
4.3.2	局部迭代偏好阈值算子集成	10
4.4	工作四：基于强化学习的多目标组合优化 (P-MOCO)	10

4.4.1	端到端强化学习条件偏好求解模型	10
4.4.2	策略梯度公式推导	11
4.5	工作五：强化学习算子与进化框架自适应选择 (RL-MOEA)	11
4.5.1	马尔可夫决策过程 (MDP) 建模机制	11
5	总结、未来展望与学术探讨	12
5.1	多目标优化与机器学习前沿发展总结	12
5.2	未来关键前沿方向讨论	12
5.3	西安交通大学李辉教授课题组招生信息	13

1 引言与多目标优化背景

在科学研究与工程实际中，人们往往面临着需要同时优化多个指标的决策问题。这与经典的单目标优化（Single-objective Optimization）存在着本质的区别：单目标优化的最优解通常是唯一的（或表现为相互等价的全局最优解集），而多目标优化（Multi-objective Optimization, MOP）由于目标函数之间存在相互冲突（Trade-off），使得其最优解并非是一个单点，而是一个由相互折中的解构成的集合。

1.1 多目标优化问题的工程应用实例

李辉教授在讲座中详细列举了多目标优化技术在重大工程、现代金融以及人工智能领域的四大应用，这些场景从实际工程物理指标到虚拟数字模型尺寸，涵盖面极广：

1. **气动工程设计（以大型客机机翼设计为例）**：在客机空气动力学外形设计中，核心关注三个相互制约的目标：

- 极小化机翼表面摩擦与压差产生的阻力 ($C_D \downarrow$)；
- 极大化在特定巡航条件下的升力 ($C_L \uparrow$)；
- 极小化结构构件的物理重量 ($W \downarrow$)。

若要追求升力最大化，通常需要增加翼展或改变翼型曲率，但这将不可避免地导致机翼重量增加和诱导阻力增大。因此，气动设计本质上是一个极复杂的连续型多目标寻优过程。

2. **金融投资组合（Portfolio Optimization）**：这是马科维茨（Markowitz）均值-方差模型的现代拓展。在不确定的金融市场中，投资者在构建资产配比时面临两个冲突的目标：

- 期望收益率最大化 ($\mathbb{E}[R] \uparrow$)；
- 资产组合收益率的方差（代表风险）最小化 ($\text{Var}(R) \downarrow$)。

高期望收益必然要求增加在波动剧烈、风险系数高的资产上的权重，因此金融决策者需要获得一条可以描述不同风险水平下最优收益的马科维茨有效边界。

3. **深度神经网络（DNN）架构设计**：在深度神经网络训练和神经架构搜索（NAS）中，研究人员通常要求模型在性能和开销之间取得良好的平衡：

- 最小化模型在验证集上的分类或回归误差 (Error $\downarrow$)；
- 最小化模型的硬件占用，如参数量 (FLOPs / Model Size $\downarrow$)。

该问题在边缘端或嵌入式芯片部署大模型时表现得尤为突出，需要实现高度轻量化且高精度的模型压缩。

4. **运载火箭回收姿态控制（以长征系列火箭回收为例）**：在垂直落体着陆回收过程中，复杂的控制逻辑必须同时兼顾：

- 燃料消耗量最小化 (Fuel Cost $\downarrow$)，以保留足够的有效载荷空间；

- 着陆点的空间位置偏差与速度偏差最小化 (Landing Error ↓)，以确保安全稳妥回收。

如果希望控制精度极高，就需要发动机频繁调整喷管喷射状态，势必消耗大量燃料，故这属于典型的卡尔曼滤波与反馈控制下的多目标约束动力学寻优。

2 多目标优化的数学理论基础

为了对上述应用进行严谨的数学刻画，本节给出多目标优化的标准数学形式与偏序关系理论。

2.1 标准数学模型

定义 2.1 (多目标优化问题 (MOP)). 一个标准的多目标优化问题可以表述为：

$$\min_{x \in \Omega} F(x) = (f_1(x), f_2(x), \dots, f_m(x))^T \quad (1)$$

其中：

- $x = (x_1, x_2, \dots, x_n)^T \in \Omega$ 表示 n 维决策向量 (Decision Vector), $\Omega \subset \mathbb{R}^n$ 称为决策空间 (Decision Space) 或可行域 (Feasible Region)。
- $F : \Omega \rightarrow \Theta \subset \mathbb{R}^m$ 是目标向量值函数，其中 Θ 称为目标空间 (Objective Space)。
- $f_i(x)$ 表示第 i 个目标函数 ($m \geq 2$)。若无特别说明，各目标函数均按极小化处理（极大化问题可通过乘以 -1 转换为极小化形式）。

2.2 帕累托支配与最优性理论

由于多目标问题中各个目标相互冲突，无法直接在实数域内利用全序关系 (Total Order) 比较大小，因此必须在多维欧氏空间 $\mathbb{R}^m$ 中定义一种基于弱偏序 (Weak Partial Order) 的关系，称为帕累托支配 (Pareto Dominance)。

定义 2.2 (帕累托支配 (Pareto Dominance)). 对于任意两个可行解 $x^a, x^b \in \Omega$ ，称 x^a 支配 x^b (记作 $x^a \prec x^b$ 或 x^a dominates x^b)，当且仅当满足以下两个条件：

$$\forall i \in \{1, 2, \dots, m\} : f_i(x^a) \leq f_i(x^b) \quad (2)$$

并且：

$$\exists j \in \{1, 2, \dots, m\} : f_j(x^a) < f_j(x^b) \quad (3)$$

直观理解，解 x^a 支配 x^b 代表 x^a 在所有目标函数上的表现都不比 x^b 差，且至少在某一个目标函数上比 x^b 更好。

定义 2.3 (帕累托最优解 (Pareto Optimal Solution)). 若可行解 $x^* \in \Omega$ 是帕累托最优的，当且仅当在可行域 Ω 内不存在任何其他可行解 $x \in \Omega$ 满足 $x \prec x^*$ 。

定义 2.4 (帕累托最优解集 (Pareto Set, PS)). 所有帕累托最优解在决策空间中的集合称为帕累托最优解集 (Pareto Set, PS)，数学表达为：

$$PS = \{x^* \in \Omega \mid \nexists x \in \Omega : x \prec x^*\} \quad (4)$$

定义 2.5 (帕累托前沿 (Pareto Front, PF)). 帕累托最优解集对应的目标向量在目标空间中的映射图像称为帕累托前沿 (Pareto Front, PF), 数学表达为:

$$PF = \{F(x^*) \in \mathbb{R}^m \mid x^* \in PS\} \quad (5)$$

对于决策者而言, 多目标优化的核心宗旨不是去寻找单一的最优点, 而是尽可能完整、均匀地刻画并逼近整个帕累托前沿 PF, 以便根据具体的偏好或实际工程条件进行多属性决策。

2.3 多目标优化问题的关键挑战特征

李辉教授在讲座中详细归纳了经典多目标优化在实际求解时面临的六大挑战性问题特征:

- **最优解集合几何形状的复杂性**: 帕累托前沿曲面可能是连续的、非连续的 (Discontinuous)、非凸的 (Non-convex)、甚至是局部退化的。如图 1 所示, 经典基准问题 (Benchmark) 中, DTLZ2 的 PF 是一个光滑对称的凸曲面, 而 DTLZ5 则由于目标冗余发生退化, PF 沦为一条空间曲线。
- **空间维数灾难**: 包括决策空间的维度 n 和目标空间的维度 m 。
 - **超多目标优化问题 (Many-objective Optimization, MaOP, $m \geq 4$)**: 随着目标数 m 的增加, 由于空间维度呈指数级扩张, 随机生成的绝大多数解在帕累托意义下会互不支配。这导致基于支配关系的进化算法 (如 NSGA-II) 丧失选择压力。
 - **大规模变量空间**: 在现代控制和复杂系统中 (如多无人机协同表演控制), 决策变量维度 n 可达成千上万, 导致极其广袤的搜索空间。
- **目标函数存在多局部极值 (Multimodality)**: 如图 2 所示, 在非线性系统优化中, 目标函数 $f(x)$ 往往包含海量的局部极小点 (Local Minima)。如果不加以全局探索, 寻优算法会非常容易陷入局部 PS/PF 集中, 而无法收敛到真正的全局最优面。
- **评估代价极高 (High Computational Cost)**: 在复杂的 CFD 流体力学或风洞计算中, 测试一组设计参数 (即评估一个 $F(x)$) 往往需要解复杂的偏微分方程, 单次计算需要耗费数小时甚至数天, 传统的梯度法或高耗代数迭代法在此类问题上彻底失效。
- **高度受约束的可行域**: 工程可行域 Ω 常由一系列非线性不等式组约束 $g_i(x) \leq 0$ 决定, 使得可行区域可能在决策空间中高度破碎。
- **时变动态与不确定性**: 实际生产部署中, 环境常含噪声或时变参数 ξ , 目标函数表现为时变轨迹 $F(x, t)$ 或统计期望值:

$$\mathbb{E}_{\xi}[F(x, \xi)] = \int_{\Xi} F(x, \xi) p(\xi) d\xi \quad (6)$$

需要算法能够在线追踪其最优解的变化。

3 传统方法与进化算法求解

针对多目标问题, 历史上发展出多种求解思想。本节重点对比传统数理规划方法与多目标进化算法 (MOEA)。

3.1 传统单目标化求解方法

传统的数理规划通常在优化前需要获取用户的先验偏好，通过某种标量化函数（Scalarizing Function）将多目标问题转化为单目标问题进行求解。

3.1.1 加权和法 (Weighted Sum Method)

加权和法是最简单、最常用的标量化手段：

$$\min_{x \in \Omega} \sum_{i=1}^m w_i f_i(x), \quad \text{s.t. } w_i \geq 0, \sum_{i=1}^m w_i = 1 \quad (7)$$

通过设置不同的权重向量 $w = (w_1, \dots, w_m)^T$ ，可以获得不同的帕累托最优解。

性质 3.1. 若各目标函数 $f_i(x)$ 均为凸函数，且可行域 Ω 为凸集，则通过改变权重 w ，加权和法可以完美找出整个帕累托前沿上的所有解。

致命缺点剖析. 如果真实的帕累托前沿是非凸的（Non-convex PF，例如呈现向目标空间原点方向凹陷的曲面），那么对于任何给定的正权重向量 w ，由于等目标函数值面是一族平行的超平面（由方程 $\sum w_i f_i = c$ 定义），其最优值只可能在非凸 PF 曲面的边界突出部分（即凸包 Corner 处）取得。因此，非凸前沿上凹陷区域中的所有帕累托最优解，在数学上均无法通过加权和法被搜索出来。 $\square$

3.1.2 ϵ -约束法 (ϵ -Constraint Method)

为了克服非凸 PF 无法求解的难题， ϵ -约束法选择将其中一个主目标作为唯一的优化目标，而将其其他所有目标限制在给定的上限阈值内：

$$\min_{x \in \Omega} f_j(x), \quad \text{s.t. } f_i(x) \leq \epsilon_i \quad (\forall i \neq j) \quad (8)$$

该方法虽然可以获得非凸前沿上的解，但其严重依赖于决策者对阈值参数 ϵ_i 的先验估计。若估计区间不当，单目标子问题将极易出现无解（Infeasible）或平凡解的情况，且在计算上，每次重新规划仅能提供帕累托前沿上的一个单点，欲描绘完整前沿需要极其庞大的循环计算开销。

3.2 多目标进化算法 (MOEA) 机制

进化算法不依赖于目标函数的梯度信息，而是利用群体并行搜索，在一轮迭代中直接搜索并维护一个分布均匀的帕累托解集。

3.2.1 NSGA-II (Deb et al., 2000)

非支配排序遗传算法（NSGA-II）是多目标寻优中的里程碑式成果。其选择算子基于两个核心机制：

1. **快速非支配排序 (Fast Non-dominated Sorting):** 将当前种群分成不同的非支配层级 $F_1, F_2, \dots$ 。优先选择层级较低（更逼近最优 PF）的个体。

2. **拥挤距离排序 (Crowding Distance Sorting)**: 在同一个非支配层内, 为了保证个体在整个帕累托前沿上的分布足够均匀, NSGA-II 引入拥挤距离 d_i 。对于每一个体 i , 其拥挤距离是指它在各目标维度的方向上与相邻两个个体的欧氏矩形周长:

$$d_i = \sum_{k=1}^m \frac{f_k(i+1) - f_k(i-1)}{f_k^{\max} - f_k^{\min}} \quad (9)$$

拥挤距离越大, 说明该个体周围的其他个体越稀疏, 其在多样性保持上的价值越高。

3.2.2 MOEA/D (Zhang & Li, 2007)

李辉教授在其博士期间, 与著名学者张青富教授合作, 提出了基于分解的多目标进化算法 (MOEA/D), 该方法现已成为进化计算最核心的经典基准方法之一。

- **分解机制**: MOEA/D 首先利用 N 个预定义且分布均匀的权重向量 $\lambda^1, \dots, \lambda^N$ 。利用切比雪夫 (Tchebycheff) 方法或边界交叉 (PBI) 法将复杂多目标优化问题分解为 N 个单目标或双目标标量化子问题。例如, 第 i 个子问题的切比雪夫形式表述为:

$$\min_{x \in \Omega} g^{tc}(x | \lambda^i, z^*) = \max_{1 \leq j \leq m} \{ \lambda_j^i |f_j(x) - z_j^*| \} \quad (10)$$

其中 z^* 为参考点 (通常是全局极小边界点)。

- **协同优化**: 每个子问题由种群中的一个解来对应。MOEA/D 定义权重空间中相邻的子问题构成一个邻域 (Neighborhood)。在进化算子操作中, 相邻解之间进行信息共享和协同交叉重组。这种邻近信息共享机制大幅度降低了重复评估的代价, 展现出比 NSGA-II 明显更快的收敛速度, 尤其在处理变量高度关联的高维复杂决策空间时表现卓越。

4 多目标优化与机器学习的前沿交叉研究

多目标进化算法在面临大规模参数搜索或高评估开销时, 存在着计算量庞大、局部搜索能力差等缺陷; 而机器学习在数据重构、流形近似和动态调参上展现出极为突出的建模优势。交叉研究具有两大双向流向, 其框架体系可用图 3 表示。




图 1: 多目标优化与机器学习双向交叉前沿框架图

本节将针对李辉教授在讲座中系统剖析的五个代表性交叉工作进行深度推导。

4.1 工作一：基于流形分布估计的进化算法 (RMM-EDA)

分布估计算法 (EDA) 是一种基于概率建模机制的进化算法。在一定的光滑约束条件下, 决策空间中的帕累托最优集 PS 具有优美的低维规则性特征。

4.1.1 流形分布的数学机理

在温和边界条件下， m 维目标空间的边界解集对应的 PS 在决策空间中是一个一维、甚至 $m - 1$ 维的连续可微流形（Manifold）。这意味着，如果我们要高效率地产生极优解，种群不应当杂乱地分布在整个 $\mathbb{R}^n$ 中，而应当聚集在 PS 这个低维几何曲面附近。为此，RM-MEDA 提出对种群通过流形学习（Manifold Learning）进行概率估计建模。

4.1.2 局部主成分分析 (Local PCA) 精准推导

由于真实的流形结构通常具有非线性、大范围弯曲和高度弯折等特征，整体 PCA（主成分分析）无法精确描述。RM-MEDA 提出采用局部主成分分析（Local PCA, LPCA）来分段近似和逼近该低维流形：

1. **局部划分**：对于当前种群，通过 k -均值（ k -Means）或基于欧氏距离的 K -最近邻（KNN）分类，将种群划分为若干子区间。
2. **协方差矩阵重构**：对于每一个局部空间中的子样本集 S ，计算其均值 $\bar{x} = \frac{1}{|S|} \sum_{x \in S} x$ ，并构造局部协方差矩阵 C ：

$$C = \frac{1}{|S| - 1} \sum_{x \in S} (x - \bar{x})(x - \bar{x})^T \quad (11)$$

3. **谱分解与降维**：对协方差矩阵 C 展开特征值谱分解：

$$C = U \Sigma U^T \quad (12)$$

其中特征向量矩阵 $U = [U^1, U^2, \dots, U^n]$ 及其对应递减特征值 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n$ 。为了描述 $m - 1$ 维切流形，保留前 $d = m - 1$ 个主特征向量 $U^1, \dots, U^d$ ，剩余成分则视为正交于流形的局部切空间噪声。

4. **流形采样 (Manifold Sampling)**：在对应的 d 维切空间上随机采样新样本。令 $\theta_i \in [-1, 1]$ 为独立均匀分布，产生的新子代为：

$$x^{\text{new}} = \bar{x} + \sum_{j=1}^d \theta_j \sqrt{\sigma_j} U^j + \epsilon \quad (13)$$

其中 $\epsilon \sim \mathcal{N}(0, \sigma_{\text{noise}}^I)$ 。

该采样方式确保了新生成的个体始终沿切空间方向生成。相较于传统变异算子，极大消除了偏离最优点的不必要探索，尤其在复杂的弯曲 PF 形状上，其展现出大幅度优于经典 NSGA-II 算法的稳定规则前沿。

4.2 工作二：克里金模型与昂贵优化算法 (MOEA/D-EGO)

针对每一次性能评价都需要耗费极高昂贵物理/数值开销（如 3D Multimodal 复杂机翼 CFD 参数计算）的情景，不能频繁直接调用原系统，需要利用机器学习代理模型（Surrogate Model）替代评估。

4.2.1 高斯随机过程模型 (Kriging / Gaussian Process) 的形式化推导

Kriging 模型能对未知输入给出预测分布。给定观测数据集 $D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(k)}, y^{(k)})\}$, Kriging 将函数分布假定为一个均值为 μ 、噪声协方差呈空间关联的高斯过程:

$$y(x) = \mu + \epsilon(x) \quad (14)$$

在空间中两个输入 $x^{(i)}, x^{(j)}$ 之间的误差关联定义为空间距离的加权高斯指数相关核:

$$\text{Corr}[\epsilon(x^{(i)}), \epsilon(x^{(j)})] = \exp \left[-d(x^{(i)}, x^{(j)}) \right], \quad \text{其中 } d(x^{(i)}, x^{(j)}) = \sum_{h=1}^n \theta_h \left| x_h^{(i)} - x_h^{(j)} \right|^{p_h} \quad (15)$$

这里超参数 $\theta_h \geq 0$ 表示各维决策变量的重要度程度, $p_h \in [1, 2]$ 控制关联强度的衰减曲率, 可以通过极小化似然函数拟合所得。

对于任何未测未知点 x , Kriging 预测结果呈高斯分布, 即给出预测均值 $\hat{y}(x)$ 及其方差值 $s^2(x)$ (表示模型在 x 处的预测不确定度):

$$\hat{y}(x) = \hat{\mu} + r^T R^{-1} (y_D - \mathbf{1} \hat{\mu}) \quad (16)$$

$$s^2(x) = \sigma^2 \left(1 - r^T R^{-1} r + \frac{(1 - \mathbf{1}^T R^{-1} r)^2}{\mathbf{1}^T R^{-1} \mathbf{1}} \right) \quad (17)$$

其中 R 对应历史数据的关联矩阵, $r = [\text{Corr}(x, x^{(1)}), \dots, \text{Corr}(x, x^{(k)})]^T$ 为关联向量。

4.2.2 极大化期望改进 (Expected Improvement, EI) 机制

在单分解子问题中, 不能一味选择均值预测值极小的解 (开发 Exploitation), 而需要考虑方差极大处的未知探索 (探索 Exploration)。为此, 引入 “极大化期望改进” (EI) 采集指标:

$$\text{EI}(x) = \mathbb{E} [\max(g_{\min} - Y, 0)] \quad (18)$$

其中 $Y \sim \mathcal{N}(\hat{y}(x), s^2(x))$ 为代理模型给出的估计高斯分布, $g_{\min}$ 为目前该子问题已经搜索到的真实最小值。通过对高斯概率积分, 可以得出闭式 (Analytical Form) 形式:

$$\text{EI}(x) = (g_{\min} - \hat{y}(x)) \Phi \left(\frac{g_{\min} - \hat{y}(x)}{s(x)} \right) + s(x) \phi \left(\frac{g_{\min} - \hat{y}(x)}{s(x)} \right) \quad (19)$$

其中 Φ 和 ϕ 分别表示标准正态分布的累积概率函数和概率密度函数。通过进化优化寻找使各子问题 $\text{EI}(x)$ 最大化的候选解, 接着对此候选解进行一次原系统的真实物理实验评估, 更新克里金代理数据库。这种 MOEA/D-EGO 机制使得仅用区区几十次物理试验, 就能在极低评估开销下精准搜索到帕累托前沿。

4.3 工作三: 基于多目标优化的稀疏重构与稀疏学习 (SPLS)

在信息科学与医学诊断的核磁共振图像 (MRI) 成像中, 往往需要在压缩感知意义下对信号进行稀疏重构。

4.3.1 稀疏 L0 双目标问题转化

传统的稀疏逼近模型表示为如下形式：

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|y - Ax\|_2^2 + \lambda \|x\|_0 \quad (20)$$

其中 $\|x\|_0$ 表示解非零元个数（即 L_0 范数，表示稀疏度）。然而，该公式最致命的缺陷在于，惩罚正则化系数 λ 很难合理确定。李辉教授等将该问题转化为一个无需设置任何人为强加正则化系数的、完全解耦的干净双目标优化问题：

$$\min_{x \in \mathbb{R}^n} \left\{ f_1(x) = \|x\|_0, f_2(x) = \frac{1}{2} \|y - Ax\|_2^2 \right\} \quad (21)$$

4.3.2 局部迭代偏好阈值算子集成

多目标算法将决策面导向帕累托前沿的“拐角面”（Knee Region）。因为物理上该区域对应着在最稀疏项下，误差开始发生陡降的极小极限特征位置。为了加速局部寻优，SPLS 巧妙引入并融合了著名的非凸非光滑数值迭代阈值算子 $\mathcal{H}_{\lambda,\mu}$ （例如经典的迭代硬阈值或者徐宗本院士提出的 $L_{1/2}$ 阈值算法）：

$$B_t = x_t + \mu A^T (y - Ax_t) \quad (22)$$

$$x_{t+1} = \mathcal{H}_{\lambda,\mu}(B_t) \quad (23)$$

其中 $L_{1/2}$ 阈值算子的分量解析表达：

$$\mathcal{H}_{\lambda,\mu}^{1/2}(z) = \begin{cases} \frac{2}{3}z \left(1 + \cos \left(\frac{2\pi}{3} - \frac{2}{3} \arccos \left(\frac{\lambda\mu}{4} \left(\frac{|z|}{3} \right)^{-3/2} \right) \right) \right) \text{sgn}(z), & \text{若 } |z| > \frac{\sqrt[3]{54}}{4} (\lambda\mu)^{2/3} \\ 0, & \text{其他} \end{cases} \quad (24)$$

这使得算法可以在完全无需人为猜测稀疏度和设置 λ 的情形下，全自动、高质量、鲁棒地重构出极其精准的真实信号和医学核磁扫描图像（见脑部 MRI 重构对比实验）。

4.4 工作四：基于强化学习的多目标组合优化 (P-MOCO)

多目标旅行商问题（MOTSP）和路径调度规划等属于复杂的非凸离散组合优化问题，传统方法极度依赖于繁琐的人工规则和低效的串行计算。

4.4.1 端到端强化学习条件偏好求解模型

李辉教授与张青富老师课题组在 ICLR 2022 上提出了基于深度强化学习的 P-MOCO（Pareto Set Learning for Neural Multiobjective Combinatorial Optimization）模型。核心是利用神经网络设计一个端到端的多目标动作策略网络 $\pi_\theta(a | s, \lambda)$ ，该策略神经网络的参数由共享权重 θ 控制。不仅输入当前问题的图节点状态 s （如 TSP 的节点坐标），同时将当前用户期望的目标权重偏好向量 $\lambda \in \mathbb{R}^m$ 显式地输入进网络中。

4.4.2 策略梯度公式推导

在网络离线训练阶段，利用强化学习，对网络进行整体策略参数优化。每一次迭代时，随机采样一个权值向量 λ ，并根据生成的路径动作输出评估奖励。策略梯度的数学更新表达式为：

$$\nabla \mathcal{J}(\theta | \lambda, s) = \mathbb{E}_{\pi \sim p_{\theta(\lambda)}(\cdot | s)} [(L(\pi | \lambda, s) - b(s | \lambda)) \nabla_{\theta(\lambda)} \log p_{\theta(\lambda)}(\pi | s)] \quad (25)$$

其中：

- $L(\pi | \lambda, s)$ 为在偏好参数 λ 下标量化的多目标反馈损失奖励：

$$L(\pi | \lambda) = \max_{1 \leq i \leq m} \{\lambda_i |L_i(\pi) - (z_i^* - \epsilon)|\} \quad (26)$$

- $b(s | \lambda)$ 对应基线函数（Baseline Function），用于降低策略梯度估计的方差。

推理的即时高效性：一旦离线训练结束，对于给定的一个新 MOTSP 或 MOCVRP 算例。当用户任意给出一组偏好权重向量 λ ，前向网络无需再进行任何复杂的遗传选择或耗时繁复的数值解法算子重构，只需要耗时不足一秒的一次高速前向传播网络运算（Fast Forward Inference），即可输出帕累托最优前沿上的一个极高质量单解方案。在多目标旅行商（MOTSP）、车辆路径问题（MOCVRP）等多项基准上，P-MOCO 在解的质量和求解速度上均表现出显著优势。

4.5 工作五：强化学习算子与进化框架自适应选择 (RL-MOEA)

没有一种单一进化算法能在面对未知现实复杂问题时一直保持完美。因此，如何根据当前代数的收敛度情况，自适应决定采用哪种算法架构以及用何种杂交演化交叉算子，是一个亟待攻克科学难关。

4.5.1 马尔可夫决策过程 (MDP) 建模机制

李辉教授于 2026 年发表在 Applied Soft Computing 上的工作将种群的动态进化迭代过程抽象地定义为一个具有控制论特征的马尔可夫决策过程（MDP）。其四大要素推导与定义如下：

- **状态空间** $S_k = (s_1, s_2)$ ：通过设计轻量级、不失一般性的种群几何指标，实时监控并反馈种群在整个目标空间中的状态：

- **收敛度描述** (s_1)：用当前代的平均适应度重心变化来刻画：

$$s_1 = \frac{1}{N \cdot m} \sum_{i=1}^N \sum_{j=1}^m f_j(x_i) \quad (27)$$

- **多样性描述** (s_2)：刻画当前最外层边界超方体的外切网格分布。
- **动作空间** A_k ：在每一代进化中，强化学习智能体（Agent）可供选择采取的优化策略动作为：

1. 选用哪种基础优化算法框架：

- NSGA-II 算法框架（侧重全局高维探索）；
- MOEA/D 算法框架（侧重邻域细密开发）；

- M2M 分区域算法框架（侧重多子空间分割）。

2. 选用何种进化重组算子：

- SBX（模拟二进制交叉算子，基于父本几何中点采样）；
- DE（差分进化算子，沿着差分方向向量采样）。

从而，动作组合空间共有 $3 \times 2 = 6$ 种可供选择动作。

- **奖励空间 R_k** ：用超体积指标（Hypervolume, HV）的变化作为强化学习的反馈奖励。当前代 k 相比前代 $k-1$ 产生的高质量解面所增加的外部网格体积增量（见图 4 示意，HV Value Δ 越大说明对前沿的逼近和覆盖越完美）：

$$R_k = \text{HV}(P_k) - \text{HV}(P_{k-1}) \quad (28)$$

若算法不收敛或多样性变差，则给予惩罚性的零奖励。

通过在线训练深度强化学习 Deep Q-Network (DQN) 网络，使模型动态在线预测和评估选用各动作序列能够带来的累计期望长期折扣奖励。DQN 对应的时序差分误差 (TD-Error) 更新公式：

$$L_{\text{DQN}}(\theta) = \mathbb{E} \left[\left(R_k + \gamma \max_{a'} Q(S', a'; \theta^-) - Q(S, A; \theta) \right)^2 \right] \quad (29)$$

实验表明（对 ZUM3, ZUM5, ZUM6 混合复杂测试题的对比），DQN 决策体不仅可以在最早期自动选择 NSGA-II 结合拓展 SBX 以扫清全局，还能在末期快速自适应地转换选用 MOEA/D 配套 DE 做深部微区寻优开发，具有极高的灵巧收敛与多样性保持。

5 总结、未来展望与学术探讨

5.1 多目标优化与机器学习前沿发展总结

综上所述，多目标优化与机器学习的前沿交叉呈现出极为强烈的双向赋能关系：

表 1: 机器学习辅助多目标进化算法代表性交叉工作归纳

交叉代表性算法	所融合的机器学习核心机理	解决的核心物理/工程痛点
RMM-EDA	局部切空间谱分解 (Local PCA)	精准拟合约束下决策空间的最优流形分布
MOEA/D-EGO	克里金代理高斯过程 (Kriging GP) & EI 采集	极大压缩 CFD/风洞昂贵测试评估所需的次数
SPLS	非凸 $L_{1/2}$ 迭代阈值算子集成	无需先验假设下高分辨率重构稀疏含噪图像
P-MOCO	端到端多目标强化学习条件控制	秒级推理解决 MOTSP 等极难非连续离散问题
RL-MOEA	深度强化学习 DQN 自适应网络	处理混合复杂极值特性下的自适应框架切换

5.2 未来关键前沿方向讨论

李辉教授认为，针对本交叉领域，未来的学术和工程探索仍需要重点解决以下三个方向：

- **大规模高维复杂黑盒函数的保真度**：构建针对更高变量维度的深度非线性高斯过程、Transformer 代理模型架构，以降低高保真度评估下的拟合偏差。

- 在工业时变控制系统中的硬实时性 (**Real-time Constraint**): 如何进一步提升 P-MOCO 等快速前向模型的泛化边界, 在毫秒级微秒级控制实体中快速对时变风偏或随机干扰做出控制姿态的最优调整。
- 不确定性多目标物理建模: 将概率测度理论进一步和动态 MOEA 相结合。

5.3 西安交通大学李辉教授课题组招生信息

李辉教授现任西安交通大学数学与统计学院计算科学系教授、博士生导师。他在这项前沿交叉学科方向深耕了逾 20 年。课题组科研实力雄厚, 师生氛围融洽, 与国内外一流学术机构和大型工业企业保持着非常密切的学术横向课题。

- 招生及报考大方向: 运筹学与优化 (智能优化算法、多目标决策理论、优化与深度学习)。
- 接收对象: 欢迎具有深厚数学、数理基础, 且具备优秀编程实践能力的免试保研生、考研生以及申请考核制博士生主动报考与探讨。
- 导师直接联络通路 (手机及微信同号): 18700589858。